符号表

Summary of Notation

大写字母用于随机变量，小写字母用于随机变量的取值与标量函数。要求取实数值的量用粗体小写字母书写，即使它是随机变量。矩阵用粗体大写字母书写。

$\doteq$	定义为真的相等关系
$\approx$	近似等于
$\propto$	正比于
$\Pr\{X = x\}$	随机变量 X 取值 x 的概率
$X \sim p$	随机变量 X 取自分布 $p(x) \doteq \Pr\{X = x\}$
$\mathbb{E}[X]$	随机变量 X 的期望，即 $\mathbb{E}[X] \doteq \sum_x p(x)x$
$\arg\max_a f(a)$	使 $f(a)$ 取到最大值的 a 的取值
$\ln x$	x 的自然对数
$e^x, \exp(x)$	自然对数的底 $e \approx 2.71828$ 的 x 次幂；$e^{\ln x} = x$
$\mathbb{R}$	实数集合
$f : \mathcal{X} \to \mathcal{Y}$	从集合 $\mathcal{X}$ 的元素到集合 $\mathcal{Y}$ 的元素的函数 f
$\leftarrow$	赋值
$(a, b]$	a 与 b 之间的实数区间，包含 b 但不包含 a
ε	ε-greedy 策略中采取随机动作的概率
α, β	步长参数
γ	折扣率参数
λ	资格迹的衰减率参数
$\mathbb{1}_{\text{predicate}}$	指示函数，当 predicate 为真时 $\mathbb{1}_{\text{predicate}} \doteq 1$，否则为 0

多臂赌博机问题中：

k	动作（臂）的个数
t	离散时间步或博弈次数
$q_*(a)$	动作 a 的真实值（期望奖励）
$Q_t(a)$	时刻 t 对 $q_*(a)$ 的估计
$N_t(a)$	时刻 t 之前动作 a 被选择的次数
$H_t(a)$	时刻 t 选择动作 a 的习得偏好
$\pi_t(a)$	时刻 t 选择动作 a 的概率
$\overline{R}_t$	时刻 t 对给定 π_t 时期望奖励的估计

马尔可夫决策过程（MDP）中：

s, s'	状态
a	一个动作
r	一个奖励
$\mathcal{S}$	所有非终止状态的集合
$\mathcal{S}^+$	所有状态的集合，包含终止状态

$\mathcal{A}(s)$	状态 s 中可用的所有动作的集合
$\mathcal{R}$	所有可能奖励的集合，是 $\mathbb{R}$ 的有限子集
$\subset$	子集，例如 $\mathcal{R} \subset \mathbb{R}$
$\in$	属于，例如 $s \in \mathcal{S}$，$r \in \mathcal{R}$
$\lvert\mathcal{S}\rvert$	集合 $\mathcal{S}$ 的元素个数
t	离散时间步
$T, T(t)$	一个回合的最终时间步，或包含时间步 t 的那个回合的最终时间步
A_t	时刻 t 的动作
S_t	时刻 t 的状态，通常由 S_{t-1} 与 A_{t-1} 随机决定
R_t	时刻 t 的奖励，通常由 S_{t-1} 与 A_{t-1} 随机决定
π	策略（决策规则）
$\pi(s)$	确定性策略 π 下在状态 s 采取的动作
$\pi(a\lvert s)$	随机策略 π 下在状态 s 采取动作 a 的概率
G_t	时刻 t 之后的回报
h	视界，前向视角中向前看到的时间步
$G_{t:t+n}, G_{t:h}$	从 $t+1$ 到 $t+n$ 或到 h 的 n 步回报（折扣并修正）
$\overline{G}_{t:h}$	从 $t+1$ 到 h 的平坦回报（不折扣也不修正）（第 5.8 节）
G_t^λ	λ 回报（第 12.1 节）
$G_{t:h}^\lambda$	截断并修正的 λ 回报（第 12.3 节）
$G_t^{\lambda s}, G_t^{\lambda a}$	按估计的状态值或动作值修正的 λ 回报（第 12.8 节）
$p(s', r \mid s, a)$	从状态 s 采取动作 a 转移到状态 s' 并得到奖励 r 的概率
$p(s' \mid s, a)$	从状态 s 采取动作 a 转移到状态 s' 的概率
$r(s, a)$	状态 s 采取动作 a 后的期望立即奖励
$r(s, a, s')$	动作 a 下从 s 转移到 s' 的期望立即奖励
$v_\pi(s)$	策略 π 下状态 s 的值（期望回报）
$v_*(s)$	最优策略下状态 s 的值
$q_\pi(s, a)$	策略 π 下在状态 s 采取动作 a 的值
$q_*(s, a)$	最优策略下在状态 s 采取动作 a 的值
V, V_t	状态值函数 v_π 或 v_* 的数组估计
Q, Q_t	动作值函数 q_π 或 q_* 的数组估计
$\overline{V}_t(s)$	期望的近似动作值，例如 $\overline{V}_t(s) \doteq \sum_a \pi(a\lvert s) Q_t(s, a)$
U_t	时刻 t 估计的目标
δ_t	时刻 t 的时序差分（TD）误差（随机变量）（第 6.1 节）
δ_t^s, δ_t^a	TD 误差的状态特定形式与动作特定形式（第 12.9 节）
n	n 步方法中自举的步数

d	维度，即 $\boldsymbol{w}$ 的分量个数
d'	另一个维度，即 $\boldsymbol{\theta}$ 的分量个数
$\boldsymbol{w}, \boldsymbol{w}_t$	近似值函数所依据的权重的 d 维向量
$w_i, w_{t,i}$	可学习权重向量的第 i 个分量
$\hat{v}(s, \boldsymbol{w})$	给定权重向量 $\boldsymbol{w}$ 时状态 s 的近似值
$v_{\boldsymbol{w}}(s)$	$\hat{v}(s, \boldsymbol{w})$ 的另一种记法
$\hat{q}(s, a, \boldsymbol{w})$	给定权重向量 $\boldsymbol{w}$ 时状态动作对 s, a 的近似值
$\nabla \hat{v}(s, \boldsymbol{w})$	$\hat{v}(s, \boldsymbol{w})$ 关于 $\boldsymbol{w}$ 的偏导数构成的列向量
$\nabla \hat{q}(s, a, \boldsymbol{w})$	$\hat{q}(s, a, \boldsymbol{w})$ 关于 $\boldsymbol{w}$ 的偏导数构成的列向量
$\boldsymbol{x}(s)$	处于状态 s 时可见的特征向量
$\boldsymbol{x}(s, a)$	在状态 s 采取动作 a 时可见的特征向量
$x_i(s), x_i(s, a)$	向量 $\boldsymbol{x}(s)$ 或 $\boldsymbol{x}(s, a)$ 的第 i 个分量
$\boldsymbol{x}_t$	$\boldsymbol{x}(S_t)$ 或 $\boldsymbol{x}(S_t, A_t)$ 的简写
$\boldsymbol{w}^\top \boldsymbol{x}$	向量的内积，$\boldsymbol{w}^\top \boldsymbol{x} \doteq \sum_i w_i x_i$，例如 $\hat{v}(s, \boldsymbol{w}) \doteq \boldsymbol{w}^\top \boldsymbol{x}(s)$
$\boldsymbol{v}, \boldsymbol{v}_t$	用于学习 $\boldsymbol{w}$ 的次 d 维权重向量（第 11 章）
$\boldsymbol{z}_t$	时刻 t 的资格迹 d 维向量（第 12 章）
$\boldsymbol{\theta}, \boldsymbol{\theta}_t$	目标策略的参数向量（第 13 章）
$\pi(a \mid s, \boldsymbol{\theta})$	给定参数向量 $\boldsymbol{\theta}$ 时在状态 s 采取动作 a 的概率
$\pi_{\boldsymbol{\theta}}$	参数 $\boldsymbol{\theta}$ 对应的策略
$\nabla \pi(a \mid s, \boldsymbol{\theta})$	$\pi(a \mid s, \boldsymbol{\theta})$ 关于 $\boldsymbol{\theta}$ 的偏导数构成的列向量
$J(\boldsymbol{\theta})$	策略 $\pi_{\boldsymbol{\theta}}$ 的性能度量
$\nabla J(\boldsymbol{\theta})$	$J(\boldsymbol{\theta})$ 关于 $\boldsymbol{\theta}$ 的偏导数构成的列向量
$h(s, a, \boldsymbol{\theta})$	基于 $\boldsymbol{\theta}$ 在状态 s 选择动作 a 的偏好
$b(a \mid s)$	学习目标策略 π 时用于选择动作的行为策略
$b(s)$	策略梯度方法的基线函数 $b : \mathcal{S} \to \mathbb{R}$
b	MDP 或搜索树的分支因子
$\rho_{t:h}$	从时刻 t 到时刻 h 的重要性采样率（第 5.5 节）
ρ_t	仅时刻 t 的重要性采样率，$\rho_t \doteq \rho_{t:t}$
$r(\pi)$	策略 π 的平均奖励（奖励率）（第 10.3 节）
$\overline{R}_t$	时刻 t 对 $r(\pi)$ 的估计
$\mu(s)$	状态上的 on-policy 分布（第 9.2 节）
$\boldsymbol{\mu}$	所有 $s \in \mathcal{S}$ 的 $\mu(s)$ 构成的 $\lvert\mathcal{S}\rvert$ 维向量
$\lVert v \rVert_\mu^2$	值函数 v 的 μ 加权平方范数，即 $\lVert v \rVert_\mu^2 \doteq \sum_{s \in \mathcal{S}} \mu(s) v(s)^2$
$\eta(s)$	每个回合访问状态 s 的期望次数（原书第 199 页）
Π	值函数的投影算子（原书第 268 页）
B_π	值函数的贝尔曼算子（第 11.4 节）
$\boldsymbol{A}$	$d \times d$ 矩阵 $\boldsymbol{A} \doteq \mathbb{E}\left[\boldsymbol{x}_t (\boldsymbol{x}_t - \gamma \boldsymbol{x}_{t+1})^\top\right]$

$\boldsymbol{b}$	d 维向量 $\boldsymbol{b} \doteq \mathbb{E}[R_{t+1}\boldsymbol{x}_t]$
$\boldsymbol{w}_{\text{TD}}$	TD 不动点 $\boldsymbol{w}_{\text{TD}} \doteq \boldsymbol{A}^{-1}\boldsymbol{b}$，一个 d 维向量（第 9.4 节）
$\boldsymbol{I}$	单位矩阵
$\boldsymbol{P}$	π 下状态转移概率的 $\lvert\mathcal{S}\rvert \times \lvert\mathcal{S}\rvert$ 矩阵
$\boldsymbol{D}$	对角线为 $\boldsymbol{\mu}$ 的 $\lvert\mathcal{S}\rvert \times \lvert\mathcal{S}\rvert$ 对角矩阵
$\boldsymbol{X}$	以 $\boldsymbol{x}(s)$ 为行的 $\lvert\mathcal{S}\rvert \times d$ 矩阵
$\overline{\delta}_{\boldsymbol{w}}(s)$	状态 s 处 $v_{\boldsymbol{w}}$ 的贝尔曼误差（期望 TD 误差）（第 11.4 节）
$\overline{\delta}_{\boldsymbol{w}}, \text{BE}$	分量为 $\overline{\delta}_{\boldsymbol{w}}(s)$ 的贝尔曼误差向量
$\overline{\text{VE}}(\boldsymbol{w})$	均方值误差 $\overline{\text{VE}}(\boldsymbol{w}) \doteq \lVert v_{\boldsymbol{w}} - v_\pi \rVert_\mu^2$（第 9.2 节）
$\overline{\text{BE}}(\boldsymbol{w})$	均方贝尔曼误差 $\overline{\text{BE}}(\boldsymbol{w}) \doteq \left\lVert \overline{\delta}_{\boldsymbol{w}} \right\rVert_\mu^2$
$\overline{\text{PBE}}(\boldsymbol{w})$	均方投影贝尔曼误差 $\overline{\text{PBE}}(\boldsymbol{w}) \doteq \left\lVert \Pi\overline{\delta}_{\boldsymbol{w}} \right\rVert_\mu^2$
$\overline{\text{TDE}}(\boldsymbol{w})$	均方时序差分误差 $\overline{\text{TDE}}(\boldsymbol{w}) \doteq \mathbb{E}_b[\rho_t \delta_t^2]$（第 11.5 节）
$\overline{\text{RE}}(\boldsymbol{w})$	均方回报误差（第 11.6 节）